

Lucrare de laborator Nr. 2

"Analiza și vizualizarea datelor în domeniul vinurilor"

Obiectivul lucrării

Scopul acestei lucrări este să exersați tehnicile de analiză a datelor și vizualizare, utilizând un set de date despre vinuri. Veți învăța să analizați date numerice, categorice și textuale, să explorați corelațiile dintre variabile și să utilizați instrumente de vizualizare pentru a comunica rezultatele.

Setul de Date

Setul de date poate fi încărcat de pe:

https://docs.google.com/spreadsheets/d/1unZYR9MbPLpYnWJZYEIWInocD_WOis0M/edit?usp=sharing&oid=101786580928890685888&rtpof=true&sd=true

Setul de date include informații despre vinuri, având următoarele coloane:

- `country`: Țara de origine a vinului.
- `description`: Descrierea vinului (textuală).
- `designation`: Denumirea specifică dată vinului.
- `points`: Punctajul acordat vinului.
- `price`: Prețul pe sticlă (în USD).
- `province`: Provincia de origine a vinului.
- `region_1` și `region_2`: Regiunile de origine.
- `variety`: Soiurile de struguri.
- `winery`: Vinăria producătoare.
- `title`: Denumirea completă a vinului.
- `vintage`: Anul recoltei.
- `alcohol`: Cantitatea de alcool (%).
- `category`: Categoria vinului (ex.: roșu, alb, spumant).

Sarcini

1. Preprocesarea Datelor

1. Curățarea datelor:

- Identificați valorile lipsă și decideți cum să le tratați (ex.: eliminare, înlocuire cu mediana/moda).
- Verificați duplicatele și eliminați-le dacă este necesar.

2. Transformări:

- Converteți coloanele numerice în formate potrivite.
- Asigurați-vă că datele categorice sunt standardizate.
- Dacă este necesar, creați o variabilă nouă ce reflectă raportul preț/calitate

3. Explorare inițială:

- Calculați statistici descriptive pentru variabilele numerice (`price`, `points`, `alcohol`).
- Identificați distribuția variabilelor categorice (ex.: câte vinuri sunt din fiecare țară, categorie sau soi).

2. Analiza Textului (Descrierea Vinului)

1. Analiză preliminară:

- Găsiți cele mai frecvente cuvinte din coloana `description` (exclueți cuvintele comune, cum ar fi „și”, „este”).
- Determinați lungimea medie a descrierii vinurilor.

2. Wordcloud:

- Generați un **wordcloud** pentru a vizualiza cele mai frecvente cuvinte din descriere.

3. Word corellation analysis:

4.

- Efectuați o analiză de corelare a cuvintelor cele mai frecvente cu prețul și ratingul
- Efectuați o analiză de corelare a cuvintelor cele mai frecvente cu soiuri

3. Analiza Corelațiilor

1. Determinați dacă există o corelație între:
 - `price` (preț) și `points` (rating).
 - `alcohol` și `points`.
 - regiune și preț/points.
 - varietati de struguri și preț/points
2. Word correlation analysis
3. Vizualizați corelațiile folosind:
 - Efectuați o analiză de corelare a cuvintelor cele mai frecvente cu prețul și ratingul
 - Efectuați o analiză de corelare a cuvintelor cele mai frecvente cu soiuri
 - **Heatmap** pentru corelațiile numerice.
 - Scatter plots pentru relații individuale.

4. Vizualizări Avansate

1. Creați următoarele vizualizări:
 - **Distribuția punctajelor (`points`):** Folosiți un histogramă.
 - **Prețurile medii pe țară (`country`):** Folosiți un bar plot.
 - **Distribuția vinurilor după categorii și regiuni:** Folosiți un stacked bar chart.
2. Generați un scatter plot interactiv care să arate relația dintre `price` și `points`, colorat în funcție de `category`.

5. Aplicație

1. Creați o aplicație (preferabil în Streamlit) care să realizeze următoarele
 1. Filtre după diferite criterii, inclusiv raportul preț/calitate
 2. Afisare vizualizărilor descrise mai sus
 3. Căutarea vinurilor conform descrierii textuale, introduse de utilizator (Opțional, poate fi implicat OpenAI)

6. Raport Final

1. Rezumați descoperirile:
 - Ce tipare sau relații interesante ați identificat?
 - Cum influențează descrierea vinului (`description`) scorul (`points`) și prețul (`price`)?

- Ce țări sau categorii produc cele mai scumpe/cele mai bine cotate vinuri?

2. Includeți graficele generate în raport.

Instrucțiuni Tehnice

- Utilizați **Python** și librării precum `pandas`, `matplotlib`, `seaborn`, și `wordcloud`.
- Pentru analiza textului, utilizați `nltk` sau `TextBlob`.

Evaluare

Raportul va fi evaluat pe baza următoarelor criterii:

- **Corectitudinea și completitudinea analizei** (30%).
- **Calitatea vizualizărilor** (20%).
- **Integrarea analizei textului** (20%).
- **Structura și claritatea raportului final** (30%).

Exemplu Generarea unui Wordcloud:

```
from wordcloud import WordCloud

text = ' '.join(df['description'])
wordcloud = WordCloud(width=800, height=400,
background_color='white').generate(text)

plt.figure(figsize=(10, 5))
plt.imshow(wordcloud, interpolation='bilinear')
plt.axis('off')
plt.show()
```